

پروژه چهارم داده کاوی

مانی ابدی

402463104

۲. ساختار پروژه و فایل‌ها (psdr)

پروژه در قالب یک ساختار ماژولار تحت عنوان psdr پیاده‌سازی شده است:

- data/raw/: داده‌های صوتی خام ورودی (شامل دیتاست استاد، دوستان و دیتاست‌های مکمل).
- src/: هسته پردازشی پروژه متشکل از ماژول‌های مستقل:
 - preprocessing.py: پیش‌پردازش، حذف نویز و حذف سکوت.
 - augmentation.py: داده‌افزایی صوتی برای افزایش مقاومت مدل.
 - features.py: تبدیل سیگنال صوتی به تصویری فرکانسی (Log-Mel Spectrogram).
 - dataset.py: مدیریت، خواندن داده‌ها و تفکیک مستقل گویندگان.
 - model.py: معماری شبکه عصبی رزیدوال (ResNet / PSDRCNN).
 - train.py: مدیریت روند آموزش و ذخیره‌سازی وزن‌ها.
 - evaluate.py: ارزیابی روی داده‌های تست و رسم ماتریس درهم‌ریختگی (Confusion Matrix).
 - cross_validate.py: ارزیابی ۵ مرحله‌ای (Fold Cross-Validation-5) بر پایه گویندگان.
- models/: محل ذخیره وزن‌های آموزش‌دیده مدل (psdr_cnn.pt و psdr_cnn_backup.pt).
- reports/: محل ذخیره خروجی‌های بصری ارزیابی (مانند confusion_matrix.png).

۳. خط‌لوله پردازش صوتی (Audio Pipeline)

۳.۱. پیش‌پردازش (preprocessing.py)

1. **Denoising**: کاهش نویز محیطی با استفاده از کتابخانه `noisereduce`.

2. **Energy Cropping**: برش بخش‌های سکوت ابتدا و انتهای فایل بر اساس انرژی سیگنال (RMS) با حد آستانه (Threshold) ۱۵٪ توان حداکثر.

3. **Normalizing**: نرمال‌سازی دامنه صدا (Peak Normalization) جهت یکدست‌سازی ولوم تمام فایل‌ها.

۳.۲. داده‌افزایی (`augmentation.py`)

برای تقویت مدل در برابر صداهای غریبه و محیط‌های مختلف، تغییرات تصادفی زیر روی داده‌های آموزش اعمال شد:

- افزودن نویز سفید با نسبت سیگنال به نویز (SNR) بین ۱۰ تا ۲۵ دسی‌بل.

- کشیدگی یا فشردگی زمانی (Time Stretch) بین نرخ ۰.۹ تا ۱.۱.

- جابه‌جایی زمانی (Time Shift) حداکثر تا ۰.۱۵ ثانیه.

- تغییر ولوم (Gain) بین -۴ تا +۴ دسی‌بل.

۳.۳. استخراج ویژگی (`features.py`)

سیگنال‌های صوتی خام به تصویر **Log-Mel Spectrogram** تبدیل شدند:

- نرخ نمونه‌برداری: $\$16000\text{ Hz}$

- تعداد فیلترهای مل (`n_mels`): $\$40$

- طول پنجره FFT (`n_fft`): $\$400$

- طول گام (`hop_length`): $\$160$

- یکسان‌سازی طول زمان (`fixed_frames`): $\$205$ فریم (پد کردن یا برش تمامی ورودی‌ها به طول یکسان).

۴. معماری شبکه عصبی (`model.py`)

مدل پیشنهادی یک شبکه **ResNet** سفارشی به نام **PSDRCNN** است. استفاده از **Residual Blocks** (لایه‌های

میانبر) مانع از محو شدن گرادینان در لایه‌های عمیق شده و توانایی مدل را در استخراج الگوهای ریز فرکانسی (مانند

تفاوت «ص» در صفر و «س» در سه) به شدت افزایش می‌دهد.

- **Stem Layer**: یک لایه Conv2d با ۳۲ کانال، BatchNorm2d و ReLU.
- **Residual Layer 1**: ۳۲ کانال (Stride 1)
- **Residual Layer 2**: ۶۴ کانال (Stride 2 – کاهش ابعاد تصویری)
- **Residual Layer 3**: ۱۲۸ کانال (Stride 2)
- **Residual Layer 4**: ۱۲۸ کانال (Stride 2)
- **Classifier**: شامل AdaptiveAvgPool2d به ابعاد \$(4, 4)\$، لایه Flatten، لایه Linear با ۱۲۸ نرون، لایه Dropout(0.4) برای جلوگیری از بیش‌برازش (Overfitting) و لایه نهایی Linear با ۱۰ خروجی.

۵. نحوه اجرای پروژه (Workflow)

برای راه‌اندازی و استفاده از پروژه دو مسیر کلی وجود دارد:

مسیر اول: تست زنده و مستقیم با وزن‌های پیش‌آموزش‌دیده (بدون نیاز به Train)

اگر فایل مدل آموزش‌دیده (psdr_cnn_backup.pt) موجود باشد، نیازی به صرف زمان برای آموزش مجدد نیست:

1. بارگذاری اسکلت مدل PSDRCNN.
2. تزریق وزن‌های آماده از طریق `model.load_state_dict(torch.load('psdr_cnn_backup.pt'))`.
3. قرار دادن مدل در حالت ارزیابی (`model.eval()`).
4. اجرای کد تست زنده در Colab یا سیستم محلی (`realtime.py`) و گفتن عدد مقابل میکروفون.

مسیر دوم: آموزش مجدد پروژه از صفر (Re-training)

در صورت نیاز به آموزش مجدد روی داده‌های جدید:

1. دستور آموزش: `bash```
2. نحوه کارکرد: سیستم داده‌ها را بر اساس گوینده به بخش‌های Train و Val تقسیم کرده، با الگوریتم AdamW و تابع زیان CrossEntropyLoss به همراه کاهش خودکار نرخ یادگیری

(ReduceLROnPlateau) شبکه را آموزش می‌دهد و بهترین مدل را بر اساس دقت Validation ذخیره می‌سازد.

۶. نتایج ارزیابی و اعتبارسنجی (Validation Results)

۶.۱. اعتبارسنجی متقابل ۵ مرحله‌ای (cross_validate.py)

برای سنجش واقعی مدل روی گویندگان غریبه (Speaker-Independent)، الگوریتم ۵-Fold Cross Validation اجرا گردید که در آن گویندگان هر فولد کاملاً ندیده بودند:

- دقت Fold 1: 85.33%
- دقت Fold 2: 92.53%
- دقت Fold 3: 96.84%
- دقت Fold 4: 91.18%
- دقت Fold 5: 93.50%
- میانگین دقت کلی (Overall Accuracy): 91.87% (انحراف معیار: 0.0377%)

۶.۲. تحلیل خطاها (Confusion Matrix Analysis)

طبق نتایج تجمیعی ماتریس درهم‌ریختگی:

- بیشترین دقت مربوط به اعداد ۱، ۲، ۵ و ۷ بود (دقت بالای ۹۵٪).
- چالش اصلی سیستم: بیشترین خطای مدل بین عدد ۳ و ۰ رخ داد (۲۹ بار عدد ۳ به اشتباه ۰ تشخیص داده شد) که علت آن شباهت ساختار فرکانسی هجای ابتدایی و کم‌انرژی بودن صامت‌های ابتدایی آن‌هاست.

۷. نتیجه‌گیری

پروژه موفق شد به میانگین دقت ۹۱.۸۷٪ روی صداهای کاملاً غریبه دست یابد. استفاده از معماری ResNet، ترکیب داده‌افزایی صوتی و تقسیم‌بندی داده‌ها بر پایه گوینده، تضمین کرد که مدل توانایی تعمیم‌پذیری بالا داشته باشد و بتواند به عنوان یک مازول تست زنده در برنامه‌های واقعی کاربرد داشته باشد.

